# Prueba técnica: Data Engineer

Nombre: Cirino Martínez / Data Engineer.

## Sección 1: Data pipeline.

Herramientas utilizadas:

- 1. Base de datos relacional. Postgres
- 2. Herramienta para ETL. Spark 2.4.
- 3. Lenguaje de programación. Scala 2.11
- 4. Java 1.8

# 1.1 Carga de información.

Elegí la base de datos de Postgres, porque es una base de datos relacional, es open source, se adapta para trabajar en diversas plataformas, tienen buen performance en cuanto al procesamiento del volumen de datos, brinda la seguridad de control a los dato, así como es una herramienta amigable.

#### 1.2 Extracción

El dataset proporcionado data\_prueba\_tecnica\_(2)\_(1).csv, tiene el siguiente formato:

Fig.1.0. Estructura del archivo data\_prueba\_tecnica\_(2)\_(1).csv.

Para trabajar la parte ETL de este set de datos, elegí las siguientes herramientas:

- Spark 2.4.
- Scala 2.11
- Java 1.8

Por qué Spark permite el procesamiento de datos estructurados y no estructurados, además permite procesar volúmenes muy altos de datos (big data), permite utilizar funciones SQL, se integra fácilmente con lenguajes como Scala, Java, Python, R; mantiene una tolerancia a fallos, es ideal para el procesamiento distribuido, además de que es open source y por qué estoy familiarizado con la herramienta.

Lectura de data\_prueba\_tecnica\_(2)\_(1).csv

Usando Spark y lenguaje de Scala.

```
def readCSVFile(pathFile: String)(implicit spark: SparkSession): DataFrame = {
  val dfEmpty=spark.emptyDataFrame
  try {
    spark.read
        .option("inferSchema", "true") // Make sure to use string version of true
        .option("header", true)
        .option("dateFormat", "yyyy-MM-dd")
        .option("sep", ",")
        .csv(pathFile)
  }
  catch {
    case ex: AnalysisException =>
        logger.error(s"Check path about $ex ")
        dfEmpty
  }
}
```

Fig.1.1. Funcion readCSVFile en lenguaje de Scala.

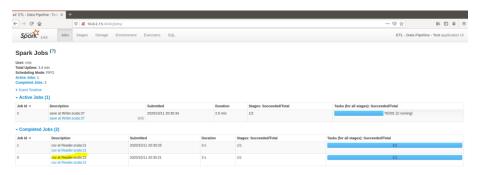


Fig.1.2. Tarea de csv at Reader.scala

Revisar el esquema del dataset:

```
ETLJobOperator ×

20/10/11 20:41:22 INFO DAGScheduler: Job 1 finished: csv at Reader.scala:21, took 0.8

root

|-- id: string (nullable = true)
|-- company_name: string (nullable = true)
|-- company_id: string (nullable = true)
|-- amount: decimal(16,2) (nullable = true)
|-- status: string (nullable = true)
|-- created_at: timestamp (nullable = true)
|-- updated_at: timestamp (nullable = true)
```

Fig.1.3. PrintSchema del dataset.

Así como una visualización de los datos.

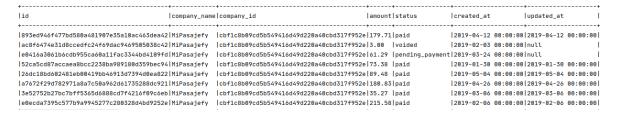
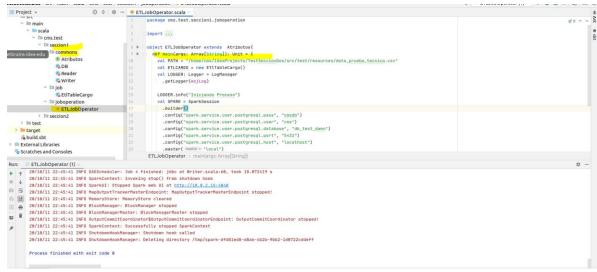


Fig.1.4. Show del dataset.

### 1.3 Transformación.



Seccion1. Código de Scala – Spark (ETL)

Transformación del campo de created\_at:

Debido a que el campo en el origen tiene diferentes formatos:

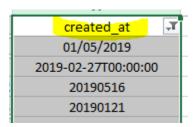


Fig.1.5. Diferentes formatos en el origen.

Implementé una función para corregirlo.

```
/**
 * @param DateField Nombre de la columna que contiene el dato de fecha en string.
 * @return Column
*/
def transformDateField(DateField: String): Column = {
  when(to_date(col(DateField), fmt = "yyyy-MM-dd").isNotNull,
    to_date(col(DateField), fmt = "yyyy-MM-dd"))
    .when(to_date(col(DateField), fmt = "yyyyMMdd").isNotNull,
      date_format(to_date(col(DateField), fmt = "yyyyMMdd"), format = "yyyy-MM-dd"))
    .when(to_date(col(DateField), fmt = "MM/dd/yyyy").isNotNull,
      to_date(col(DateField), fmt = "MM/dd/yyyy"))
    .when(to_date(col(DateField), fmt= "yyyy MMMM dd").isNotNull,
      to_date(col(DateField), fmt = "yyyy MMMM dd"))
    .when(to_date(col(DateField), fmt= "yyyy MMMM dd E").isNotNull,
     to_date(col(DateField), fmt = "yyyy MMMM dd E"))
    .otherwise( value = "Unknown Format")
    .alias(DateField)
```

Fig.1.6. Función en Scala, para formatear el campo de fecha.

- Transformación del campo de amount:
   Se convirtió a decimal (16,2) el campo.
- Filtros para evitar Null:
   En los campos de company\_id, para evitar null.

**Nota**. Se realizaron cambios en la definición del esquema propuesto.

id varchar(24) NOT NULL – Se cambió a 40 caracteres, debido a la longitud de los datos.

company id varchar(24) NOT NULL – Se cambió a 40 caracteres, debido a la longitud de los datos.

```
CREATE TABLE db_test_daen.cargo(
id varchar(40) NOT NULL,
company_name varchar(130) NOT NULL,
company_id varchar(40) NOT NULL,
amount decimal(16,2) NOT NULL,
status varchar(30) NULL,
created_at timestamp not NULL,
updated_at timestamp null)
```

```
abc id varchar(40) NOT NULL
abc company_name varchar(130) NOT NULL
company_id varchar(40) NOT NULL
123 amount numeric(16,2) NOT NULL
abc status varchar(30)
created_at timestamp NOT NULL
updated_at timestamp
```

Fig.1.7. Creación de la tabla cargo en Postgres.

## 1.4 Dispersión de los datos.

Se crearon las tablas *charges y companies*.

Se muestra el diagrama.

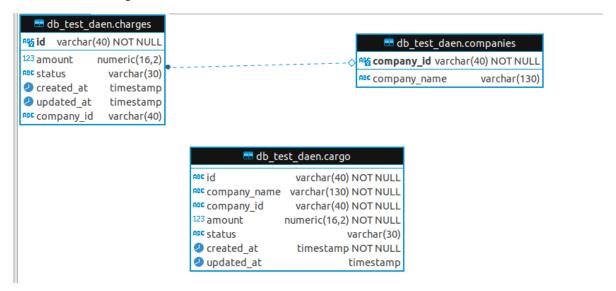


Fig.1.8. Creación de las tablas companies y charges en Postgres.

A manera de ilustración los datos se guardaron en formato Parquet, compresión snappy.

```
def saveResultSetAsParquet(df: DataFrame, saveMode: String, format: String, companyId: String, createdAt: String,
                          pathToSave: String): Unit = {
  try {
    df.write
      .mode(saveMode)
      .partitionBy(createdAt, companyId)
      .option("compression", "snappy")
      .format(format)
      .save(pathToSave)
    logger.info("The Data save into the path : ".concat(pathToSave))
  catch {
    case ex: PSQLException =>
      logger.error(s"Check table about $ex ")
                          Jobs
                                                         Environment
                                                                          Executors
                                                                                        SQL
                                   Stages
                                              Storage
SQL
Running Queries: 1
Completed Queries: 2
Running Queries (1)
        Description
                                                                         Submitted
         save at Writer.scala:36
                                                                 +details 2020/10/11 21:57:15
2
```

Fig.1.9. Función en Scala para escribir en parquet.

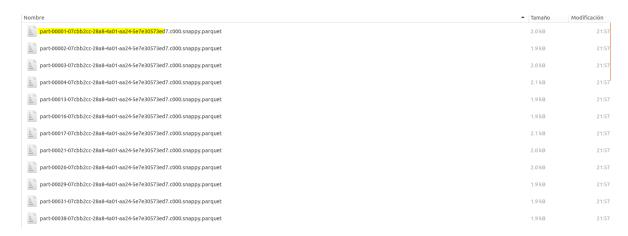


Fig.1.10. Salida de resultados.

#### Escritura en la tabla cargo de Postgres.

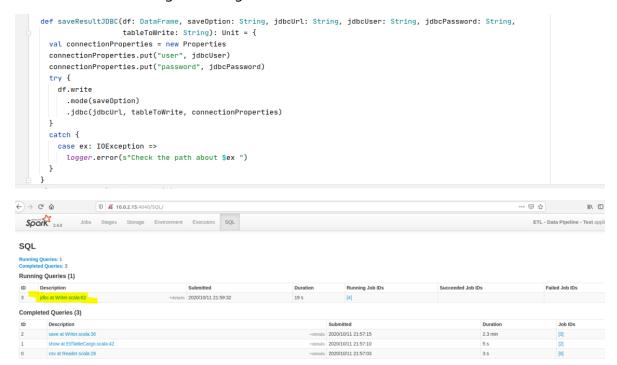


Fig.1.11. Función en Scala para escribir Postgres por medio de jdbc.

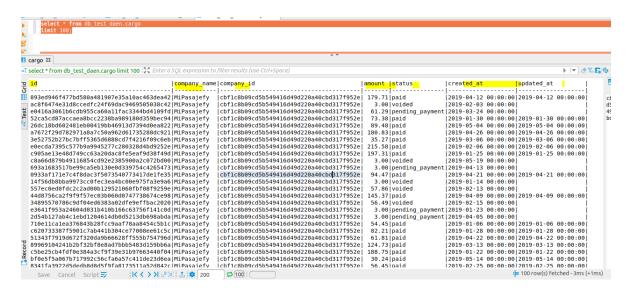


Fig.1.12. Salida de resultados en postgress.

Nota. Debido a que existían nombre diferentes nombres de companias, asociados al mismo Company\_id, realice la unificación.

```
update table cargo
update db_test_daen.cargo
set company_name ='MiPasajef'
where company_id ='cbf1c8b09cd5b549416d49d220a40cbd317f952e';
```

Fig.1.13. Update de Company\_name

Fig.1.14. carga de datos a la tabla companies.

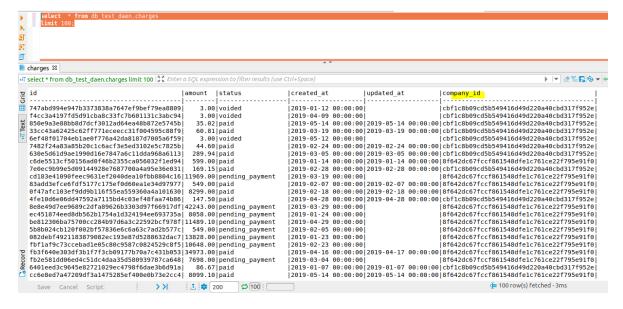
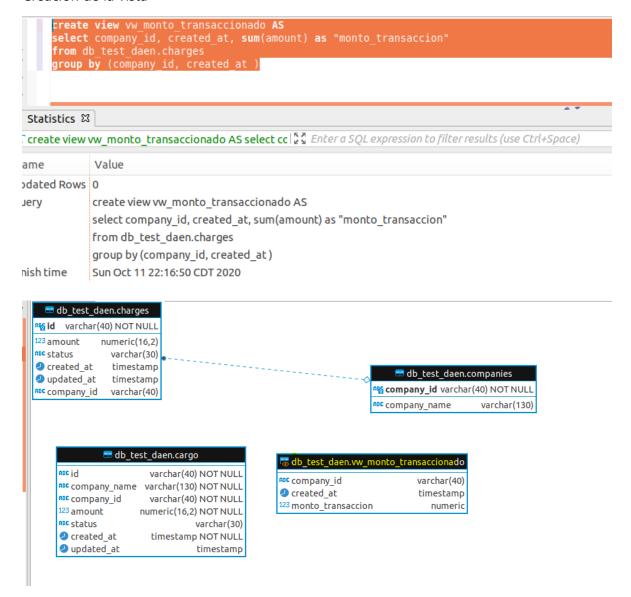


Fig.1.14. carga de datos a la tabla charges.

### 1.5 SQL.

#### Creación de la vista



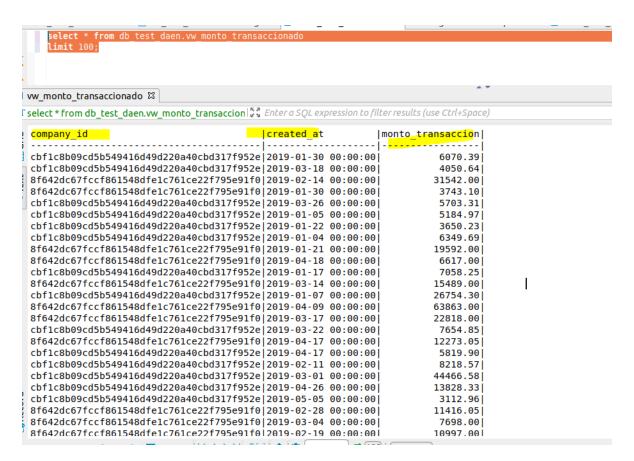


Fig.1.15. Resultados de la vista vw monto transaccionado

#### Sección 2: Scala.

Desarrollado en Scala 2.11

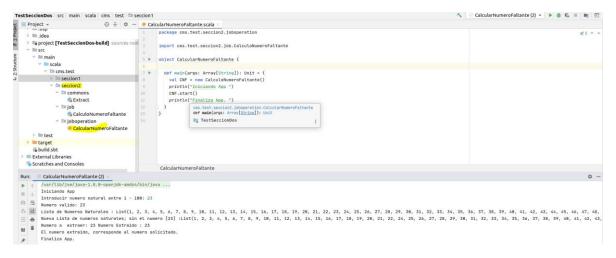


Fig.2.0. Seccion2

```
CalcularNumeroFaltante.scala ×
      package cms.test.Seccion2.joboperation
3
    import cms.test.commons.Extract
     import cms.test.job.CalculoNumeroFaltante
      object CalcularNumeroFaltante {
7
    def main(args: Array[String]): Unit = {
8
          val CNF = new CalculoNumeroFaltante()
          println("Iniciando App ")
0
          CNF.start()
          println("Finaliza App. ")
3
       }-
    ♠}
5
```

Fig.2.1. Método main()

Fig.2.2. Implementación de las funcionalidades requeridas.